深度学习与自然语言处理(4)_斯坦福cs224d 大作业测验1与解答

作业内容翻译：@胡杨(superhy199148@hotmail.com) && @胥可(feitongxiaoke@gmail.com)
解答与编排：寒小阳 && 龙心尘
时间：2016年6月
出处：
http://blog.csdn.net/han_xiaoyang/article/details/51760923
http://blog.csdn.net/longxinchen_ml/article/details/51765418

说明：本文为斯坦福大学CS224d课程的中文版内容笔记，已得到斯坦福大学课程@Richard Socher教授的授权翻译与发表

0 前言

前面一个接一个的Lecture，看得老衲自己也是一脸懵逼，不过你以为你做一个安安静静的美男子(总感觉有勇气做deep learning的女生也是一条汉纸)就能在Stanford这样的学校顺利毕业啦？图样图森破，除掉极高的内容学习梯度，这种顶尖大学的作业和考试一样会让你突(tong)飞(bu)猛(yu)进(sheng)。

说起来，怎么也是堂堂斯坦福的课，这种最看重前言研究在实际工业应用的学校，一定是理论和应用并进，对动手能力要求极强的，于是乎，我们把作业和小测验(MD你这也敢叫小测验！！)也扒过来，整理整理，让大家都来体验体验。反正博主君自己每次折腾完这些大学的assignment之后，都会感慨一句，“还好不生在水生火热的万恶资本主义国家，才能让我大学和研究僧顺利毕业(什么？phd？呵呵...博主是渣渣，智商常年处于欠费状态，我就不参与你们高端人士的趴体了)”。

不能再BB了，直接开始做作业考试吧...

1 Softmax (10 分)

(part a) (5分)
证明针对任何输入向量和常数c，softmax函数的输出不会随着输入向量偏移（也就是常数c）而改变。即：

其中就是给每一个元素加上常数c。注意：

提示：在实际应用中，经常会用到这个性质。为了稳定地计算softmax概率，我们会选择。（即将的每个元素减去最大的那个元素）。

> 博主：熬过了高中，居然又看见证明了，也是惊(ri)喜(le)万(gou)分(le)，答案拿来！！！

解答：
证明，针对所有维度：

(part b) (5 分)
已知一个N行d列的输入矩阵，计算每一行的softmax概率。在q1_softmax.py中写出你的实现过程，并使用python q1_softmax.py执行。

要求：你所写的代码应该尽可能的有效并以向量化的形式来实现。非向量化的实现将不会得到满分。

> 博主：简直要哭晕在厕所了，当年毕业设计也是加论文一星期都可以写完的节奏，这里一个5分的作业，还这么多要求...社会主义好...答案拿来！！！

```
1. import numpy as np
2. def softmax(x):
3.     """
4.         Softmax 函数
5.     """
6.     assert len(x.shape) > 1, "Softmax的得分向量要求维度高于1"
7.     x -= np.max(x, axis=1, keepdims=True)
8.     x = np.exp(x) / np.sum(np.exp(x), axis=1, keepdims=True)
9.     return x
```

2 神经网络基础（30分）

(part a) (3 分)
推导sigmoid函数的导数，并且只以sigmoid函数值的形式写出来（导数的表达式里只包含，不包含x）。证明针对这个问题没必要单独考虑x。方便回忆：下面给出sigmoid函数形式：

> 旁白：我年纪轻轻干嘛要走上深度学习这条不归路，真是生无所恋了。

答案：。

(part b) (3 分)
当使用交叉熵损失来作为评价标准时,推导出损失函数以softmax为预测结果的输入向量的梯度。注意，

其中是一个one-hot向量，是所有类别的预测出的概率向量。（提示：你需要考虑的许多元素为0，并且假设仅有第k个类别是1）

答案:
或者等价于下面表达式，其中假设k是正确的类别

(part c) (6 分)
推导出单隐层神经网络关于输入的梯度（也就是推导出，其中J是神经网络的损失函数）。这个神经网络在隐层和输出层采用了sigmoid激活函数，是one-hot编码向量，使用了交叉熵损失。（使用 作为sigmoid梯度，并且你可以任意为推导过中的中间变量命名）

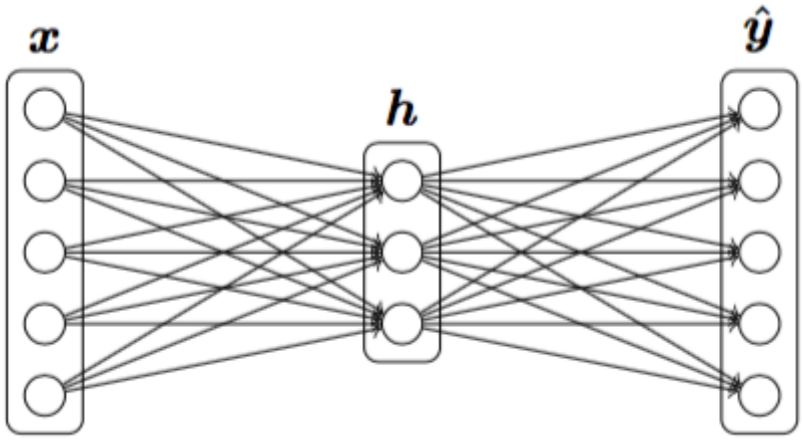

前向传播方程如下：

在编程问题中，我们假设输入向量（隐层变量和输出概率）始终是一个行向量。此处我们约定，当我们说要对向量使用sigmoid函数时，也就是说要对向量每一个元素使用sigmoid函数。和（其中i=1，2）分别是两层的权重和偏移。

> 旁白：好好的100分总分，硬要被你这么5分6分地拆，人家5分6分是一道选择题，你特么是一整个毕业设计！！好吧，不哭，跪着也要把题目做完，代码写完。哎，博主还是太年轻，要多学习啊。

答案：令，，于是可得：

(part d) (2 分)
上面所说的这个神经网络有多少个参数？我们可以假设输入是维，输出是，隐层单元有H个。

> 旁白：还有part d！！！

答案: .

(part e) (4 分) 在q2_sigmoid.py中补充写出sigmoid激活函数的和求它的梯度的对应代码。并使用python q2_sigmoid.py进行测试，同样的，测试用例有可能不太详尽，因此尽量检查下自己的代码。

> 旁白：如果博主没有阵亡，就在走向阵亡的路上...

```
1. def sigmoid_grad(f):
2.     """
3.         计算Sigmoid的梯度
4.     """
5.     #好在我有numpy
6.     f = f * ( 1 - f )
7.     return f
```

(part f) (4 分)
为了方便debugging，我们需要写一个梯度检查器。在q2_gradcheck.py中补充出来，使用python q2_gradcheck.py测试自己的代码。

> 旁白：做到昏天黑地，睡一觉起来又是一条好汉...

```
def gradcheck_naive(f, x):
    """
        对一个函数f求梯度的梯度检验
        - f 输入x，然后输出loss和梯度的函数
        - x 就是输入咯
    """
    rndstate = random.getstate()
    random.setstate(rndstate)
    fx, grad = f(x)
    h = 1e-4
    # 遍历x的每一维
    it = np.nditer(x, flags=['multi_index'], op_flags=['readwrite'])
    while not it.finished:
        ix = it.multi_index
        old_val = x[ix]
        x[ix] = old_val - h
        random.setstate(rndstate)
        ( fxh1, _ ) = f(x)
        x[ix] = old_val + h
        random.setstate(rndstate)
        ( fxh2, _ ) = f(x)
        numgrad = (fxh2 - fxh1)/(2*h)
        x[ix] = old_val
        # 比对梯度
        reldiff = abs(numgrad - grad[ix]) / max(1, abs(numgrad),
   abs(grad[ix]))
        if reldiff > 1e-5:
            print "Gradient check failed."
            print "First gradient error found at index %s" % str(ix)
            print "Your gradient: %f \t Numerical gradient: %f" % (grad[ix],
   numgrad)
            return
        it.iternext() # Step to next dimension
    print "Gradient check passed!"
```

(part g) (8 分)
现在，在q2 neural.py中，写出只有一个隐层且激活函数为sigmoid的神经网络前向和后向传播代码。使用python q2_neural.py测试自己的代码。

> 旁白：一入DL深似海...

```
def forward_backward_prop(data, labels, params, verbose = False):
    """
        2个隐层的神经网络的前向运算和反向传播
    """
    if len(data.shape) >= 2:
```

```
        (N, _) = data.shape
    ### 展开每一层神经网络的参数
    t = 0
    W1 = np.reshape(params[t:t+dimensions[0]*dimensions[1]], (dimensions[0], dimensions[1]))
    t += dimensions[0]*dimensions[1]
    b1 = np.reshape(params[t:t+dimensions[1]], (1, dimensions[1]))
    t += dimensions[1]
    W2 = np.reshape(params[t:t+dimensions[1]*dimensions[2]], (dimensions[1], dimensions[2]))
    t += dimensions[1]*dimensions[2]
    b2 = np.reshape(params[t:t+dimensions[2]], (1, dimensions[2]))
    ### 前向运算
    # 第一个隐层做内积
    a1 = sigmoid(data.dot(W1) + b1)
    # 第二个隐层做内积
    a2 = softmax(a1.dot(W2) + b2)
    cost = - np.sum(np.log(a2[labels == 1]))/N
    ### 反向传播
    # Calculate analytic gradient for the cross entropy loss function
    grad_a2 = ( a2 - labels ) / N
    # Backpropagate through the second latent layer
    gradW2 = np.dot( a1.T, grad_a2 )
    gradb2 = np.sum( grad_a2, axis=0, keepdims=True )
    # Backpropagate through the first latent layer
    grad_a1 = np.dot( grad_a2, W2.T ) * sigmoid_grad(a1)
    gradW1 = np.dot( data.T, grad_a1 )
    gradb1 = np.sum( grad_a1, axis=0, keepdims=True )
    if verbose: # Verbose mode for logging information
        print "W1 shape: {}".format( str(W1.shape) )
        print "W1 gradient shape: {}".format( str(gradW1.shape) )
        print "b1 shape: {}".format( str(b1.shape) )
        print "b1 gradient shape: {}".format( str(gradb1.shape) )
    ### 梯度拼起来
    grad = np.concatenate((gradW1.flatten(), gradb1.flatten(), gradW2.flatten(), gradb2.flatten()))
    return cost, grad
```

3 word2vec(40分+5附加分)

(part a) (3分)
假设你得到一个关联到中心词的预测词向量，并且这个词向量使用skip-gram方法生成，预测词使用的是softmax预测函数，它能够在`word2vec`模型中被找到。

式中，代表第w个词，是词库中全体词汇的输出词向量。假设为交叉熵损失函数，且词是被预测的词汇（noe-hot/独热模型的标记向量中第个元素为1），求解预测词向量 的所对应的梯度。

提示：问题2中的标记法将有助于此问题的解答。比如：设为各个词汇使用softmax函数预测得到的向量，为期望词向量，而损失函数可以表示为：

其中，是全体输出向量形成的矩阵，*确保你已经规定好你的向量和矩阵的方向。*

> 旁边：是的，旁白我已经不知道写什么了，感谢党感谢祖国吧。

解答：设为词汇softmax预测结果的列向量，是同样形为列向量的独热标签，那么有：

或者等同于：

(part b) (3分)
条件仍然如前一题所描述，求解输出词向量的梯度（包括在内）

> 旁白：我还是安安静静在天朝搬砖吧

解答：

或者等同于：

(part c) (6分)
仍然延续(part a)和(part b)，假设我们使用为预测的向量使用负采样损失的计算方式，并且设定期望输出词为。假设获得了个负样例（词），并且被记为，分别作为这些样例的标签。那么，对于一个给定的词，将其输出向量记作。这里，负采样损失函数如下：

其中，为sigmoid激活函数。

当你完成上述操作之后，尝试简要描述这个损失函数比softmax-CE损失函数计算更为有效的原因（你可以给出递增式的学习率，即，给出softmax-CE损失函数的计算时间除以负采样损失函数的计算时间的结果）。

注释：由于我们打算计算目标函数的最小值而不是最大值，这里提到的损失函数与Mikolov等人最先在原版论文中描述的正好相反。

> 旁白：突然想起来，小时候好焦虑，长大后到底去清华还是去北大，后来发现多虑了。我想如果当初走了狗屎运进了贵T大贵P大，也一定完不成学业。

解答：

(part d) (8分)
试得到由skip-gram和CBOW算法分别算出的全部词向量的梯度，前提步骤和词内容集合[wordc-m,…,wordc-1,wordc,wordc+1,…,wordc+m]都已给出，其中，是窗口的大小。将词的输入和输出词向量分别记为和。
提示：可以随意使用函数（其中代表词汇）作为这一部分中或损失函数的占位符——你将在编程部分看到一个非常有用的抽象类，那意味着你的解决方法可以用这样的形式表达：
回忆skip-gram算法，以为中心周边内容的损失值计算如下：

其中，代表距离中心词的第j个词。
CBOW略有不同，不同于使用作为预测向量，我们以

为底，在CBOW中（一个小小的变体），我们计算上下文输入词向量的和:

于是，CBOW的损失函数定义为：

注释：为了符合在诸如代码部分中的各种表达规范，在skip-gram方法中，令：。

> 旁白：我诚实一点，这个部分真的是翻了课件抄下来的。

解答：为了表达得更为清晰，我们将词库中全部词汇的全部输出向量集合记作，给定一个损失函数，我们可以很容易获得以下引出结果：
和
对于skip-gram方法，一个内容窗口的损失梯度为：

同样地，对于CBOW则有：

(part e) (12分)
在这一部分，你将实现word2vec模型，并且使用随机梯度下降方法（SGD）训练属于你自己的词向量。首先，在代码`q3_word2vec.py`中编写一个辅助函数对矩阵中的每一行进行归一化。同样在这个文件中，完成对softmax、负采样损失函数以及梯度计算函数的实现。然后，完成面向skip-gram的梯度损失函数。当你完成这些的时候，使用命令：`python q3_word2vec.py`对编写的程序进行测试。
注释：如果你选择不去实现CBOW(h部分)，只需简单地删除对NotImplementedError错误的捕获即可完成你的测试。

> 旁白：前方高能预警，代码量爆炸了！

```
1. import numpy as np
2. import random
3. from q1_softmax import softmax
4. from q2_gradcheck import gradcheck_naive
5. from q2_sigmoid import sigmoid, sigmoid_grad
6. def normalizeRows(x):
7.     """
8.         行归一化函数
9.     """
10.     N = x.shape[0]
11.     x /= np.sqrt(np.sum(x**2, axis=1)).reshape((N,1)) + 1e-30
12.     return x
13. def test_normalize_rows():
14.     print "Testing normalizeRows..."
15.     x = normalizeRows(np.array([[3.0,4.0],[1, 2]]))
16.     # 结果应该是 [[0.6, 0.8], [0.4472, 0.8944]]
17.     print x
18.     assert (np.amax(np.fabs(x - np.array([[0.6,0.8],
    [0.4472136,0.89442719]]))) <= 1e-6)
19.     print ""
20. def softmaxCostAndGradient(predicted, target, outputVectors, dataset):
21.     """
22.         word2vec的Softmax损失函数
23.     """
24.     # 输入:
25.     # - predicted: 预测词向量的numpy数组
26.     # - target: 目标词的下标
```

```
27.     # - outputVectors: 所有token的"output"向量(行形式)
28.     # - dataset: 用来做负例采样的，这里其实没用着
29.     # 输出:
30.     # - cost: 输出的互熵损失
31.     # - gradPred: the gradient with respect to the predicted word
32.     #        vector
33.     # - grad: the gradient with respect to all the other word
34.     #        vectors
35.     probabilities = softmax(predicted.dot(outputVectors.T))
36.     cost = -np.log(probabilities[target])
37.     delta = probabilities
38.     delta[target] -= 1
39.     N = delta.shape[0]
40.     D = predicted.shape[0]
41.     grad = delta.reshape((N,1)) * predicted.reshape((1,D))
42.     gradPred = (delta.reshape((1,N)).dot(outputVectors)).flatten()
43.     return cost, gradPred, grad
44. def negSamplingCostAndGradient(predicted, target, outputVectors, dataset,
45.     K=10):
46.     """
47.         Word2vec模型负例采样后的损失函数和梯度
48.     """
49.     grad = np.zeros(outputVectors.shape)
50.     gradPred = np.zeros(predicted.shape)
51.     indices = [target]
52.     for k in xrange(K):
53.         newidx = dataset.sampleTokenIdx()
54.         while newidx == target:
55.             newidx = dataset.sampleTokenIdx()
56.         indices += [newidx]
57.     labels = np.array([1] + [-1 for k in xrange(K)])
58.     vecs = outputVectors[indices,:]
59.     t = sigmoid(vecs.dot(predicted) * labels)
60.     cost = -np.sum(np.log(t))
61.     delta = labels * (t - 1)
62.     gradPred = delta.reshape((1,K+1)).dot(vecs).flatten()
63.     gradtemp = delta.reshape((K+1,1)).dot(predicted.reshape(
64.         (1,predicted.shape[0])))
65.     for k in xrange(K+1):
66.         grad[indices[k]] += gradtemp[k,:]
67.      t = sigmoid(predicted.dot(outputVectors[target,:]))
68.      cost = -np.log(t)
69.      delta = t - 1
70.      gradPred += delta * outputVectors[target, :]
71.      grad[target, :] += delta * predicted
72.      for k in xrange(K):
73.          idx = dataset.sampleTokenIdx()
```

```
74.          t = sigmoid(-predicted.dot(outputVectors[idx,:]))
75.          cost += -np.log(t)
76.          delta = 1 - t
77.          gradPred += delta * outputVectors[idx, :]
78.          grad[idx, :] += delta * predicted
79.      return cost, gradPred, grad
80. def skipgram(currentWord, C, contextWords, tokens, inputVectors,
    outputVectors,
81.      dataset, word2vecCostAndGradient = softmaxCostAndGradient):
82.      """ Skip-gram model in word2vec """
83.      # skip-gram模型的实现
84.      # 输入:
85.      # - currrentWord: 当前中心词所对应的串
86.      # - C: 上下文大小(词窗大小)
87.      # - contextWords: 最多2*C个词
88.      # - tokens: 对应词向量中词下标的字典
89.      # - inputVectors: "input" word vectors (as rows) for all tokens
90.      # - outputVectors: "output" word vectors (as rows) for all tokens
91.      # - word2vecCostAndGradient: the cost and gradient function for a
    prediction vector given the target word vectors, could be one of the two cost
    functions you implemented above
92.      # 输出:
93.      # - cost: skip-gram模型算得的损失值
94.      # - grad: 词向量对应的梯度
95.      currentI = tokens[currentWord]
96.      predicted = inputVectors[currentI, :]
97.      cost = 0.0
98.      gradIn = np.zeros(inputVectors.shape)
99.      gradOut = np.zeros(outputVectors.shape)
100.     for cwd in contextWords:
101.         idx = tokens[cwd]
102.         cc, gp, gg = word2vecCostAndGradient(predicted, idx, outputVectors,
    dataset)
103.         cost += cc
104.         gradOut += gg
105.         gradIn[currentI, :] += gp
106.     return cost, gradIn, gradOut
107. def word2vec_sgd_wrapper(word2vecModel, tokens, wordVectors, dataset, C,
    word2vecCostAndGradient = softmaxCostAndGradient):
108.     batchsize = 50
109.     cost = 0.0
110.     grad = np.zeros(wordVectors.shape)
111.     N = wordVectors.shape[0]
112.     inputVectors = wordVectors[:N/2,:]
113.     outputVectors = wordVectors[N/2:,:]
114.     for i in xrange(batchsize):
115.         C1 = random.randint(1,C)
```

```
116.         centerword, context = dataset.getRandomContext(C1)
117.         if word2vecModel == skipgram:
118.             denom = 1
119.         else:
120.             denom = 1
121.         c, gin, gout = word2vecModel(centerword, C1, context, tokens,
    inputVectors, outputVectors, dataset, word2vecCostAndGradient)
122.         cost += c / batchsize / denom
123.         grad[:N/2, :] += gin / batchsize / denom
124.         grad[N/2:, :] += gout / batchsize / denom
125.     return cost, grad
126. def test_word2vec():
127.     # Interface to the dataset for negative sampling
128.     dataset = type('dummy', (), {})()
129.     def dummySampleTokenIdx():
130.         return random.randint(0, 4)
131.     def getRandomContext(C):
132.         tokens = ["a", "b", "c", "d", "e"]
133.         return tokens[random.randint(0,4)], [tokens[random.randint(0,4)] \
134.            for i in xrange(2*C)]
135.     dataset.sampleTokenIdx = dummySampleTokenIdx
136.     dataset.getRandomContext = getRandomContext
137.     random.seed(31415)
138.     np.random.seed(9265)
139.     dummy_vectors = normalizeRows(np.random.randn(10,3))
140.     dummy_tokens = dict([("a",0), ("b",1), ("c",2),("d",3),("e",4)])
141.     print "==== Gradient check for skip-gram ===="
142.     gradcheck_naive(lambda vec: word2vec_sgd_wrapper(skipgram, dummy_tokens,
    vec, dataset, 5), dummy_vectors)
143.     gradcheck_naive(lambda vec: word2vec_sgd_wrapper(skipgram, dummy_tokens,
    vec, dataset, 5, negSamplingCostAndGradient), dummy_vectors)
144.     print "\n==== Gradient check for CBOW      ===="
145.     gradcheck_naive(lambda vec: word2vec_sgd_wrapper(cbow, dummy_tokens, vec,
    dataset, 5), dummy_vectors)
146.     gradcheck_naive(lambda vec: word2vec_sgd_wrapper(cbow, dummy_tokens, vec,
    dataset, 5, negSamplingCostAndGradient), dummy_vectors)
147.     print "\n=== Results ==="
148.     print skipgram("c", 3, ["a", "b", "e", "d", "b", "c"], dummy_tokens,
    dummy_vectors[:5,:], dummy_vectors[5:,:], dataset)
149.     print skipgram("c", 1, ["a", "b"], dummy_tokens, dummy_vectors[:5,:],
    dummy_vectors[5:,:], dataset, negSamplingCostAndGradient)
150.     print cbow("a", 2, ["a", "b", "c", "a"], dummy_tokens,
    dummy_vectors[:5,:], dummy_vectors[5:,:], dataset)
151.     print cbow("a", 2, ["a", "b", "a", "c"], dummy_tokens,
    dummy_vectors[:5,:], dummy_vectors[5:,:], dataset,
    negSamplingCostAndGradient)
152. if __name__ == "__main__":
```

```
153.     test_normalize_rows()
154.     test_word2vec()
```

(f) (4分) 在代码`q3_sgd.py`中完成对随即梯度下降优化函数的实现。并且在该代码中运行测试你的实现。

> 旁白：想到这篇文章有可能会被无数可以智商碾压我的大神看到，就脸一阵发烫。

```
1. # 实现随机梯度下降
2. # 随机梯度下降每1000轮，就保存一下现在训练得到的参数
3. SAVE_PARAMS_EVERY = 1000
4. import glob
5. import os.path as op
6. import cPickle as pickle
7. import sys
8. def load_saved_params():
9.     """
10.         载入之前的参数以免从头开始训练
11.     """
12.     st = 0
13.     for f in glob.glob("saved_params_*.npy"):
14.         iter = int(op.splitext(op.basename(f))[0].split("_")[2])
15.         if (iter > st):
16.             st = iter
17.     if st > 0:
18.         with open("saved_params_%d.npy" % st, "r") as f:
19.             params = pickle.load(f)
20.             state = pickle.load(f)
21.         return st, params, state
22.     else:
23.         return st, None, None
24. def save_params(iter, params):
25.     with open("saved_params_%d.npy" % iter, "w") as f:
26.         pickle.dump(params, f)
27.         pickle.dump(random.getstate(), f)
28. def sgd(f, x0, step, iterations, postprocessing = None, useSaved = False,
    PRINT_EVERY=10, ANNEAL_EVERY = 20000):
29.     """ 随机梯度下降 """
30.     ###############################################################
31.     # 输入
32.     #   - f: 需要最优化的函数
33.     #   - x0: SGD的初始值
34.     #   - step: SGD的步长
35.     #   - iterations: 总得迭代次数
36.     #   - postprocessing: 参数后处理（比如word2vec里需要对词向量做归一化处理）
37.     #   - PRINT_EVERY: 指明多少次迭代以后输出一下状态
38.     # 输出:
```

```
    #   - x: SGD完成后的输出参数                    #
    ##############################################################
    if useSaved:
        start_iter, oldx, state = load_saved_params()
        if start_iter > 0:
            x0 = oldx;
            step *= 0.5 ** (start_iter / ANNEAL_EVERY)
        if state:
            random.setstate(state)
    else:
        start_iter = 0
    x = x0
    if not postprocessing:
        postprocessing = lambda x: x
    expcost = None
    for iter in xrange(start_iter + 1, iterations + 1):
        cost, grad = f(x)
        x = x - step * grad
        x = postprocessing(x)
        if iter % PRINT_EVERY == 0:
            print "Iter#{}, cost={}".format(iter, cost)
            sys.stdout.flush()
        if iter % SAVE_PARAMS_EVERY == 0 and useSaved:
            save_params(iter, x)
        if iter % ANNEAL_EVERY == 0:
            step *= 0.5
    return x
```

(part g) (4分)

开始秀啦！现在我们将要载入真实的数据并使用你已经实现的手段训练词向量！我们将使用Stanford Sentiment Treebank (SST)数据集来进行词向量的训练，之后将他们应用到情感分析任务中去。在这一部分中，无需再编写更多的代码；只需要运行命令`python q3_run.py`即可。

*注释：训练过程所占用的时间可能会很长，这取决于你所实现的程序的效率（**一个拥有优异效率的实现程序大约需要占用1个小时**）。努力去接近这个目标！*

当脚本编写完成，需要完成对词向量的可视化显示。相应的结果同样被保存下来，如项目目录中的图片`q3_word_vectors.png`所示。**包括在你作业中绘制的坐标图**。简明解释最多三个句子在你的坐标图中的显示状况。

解答：

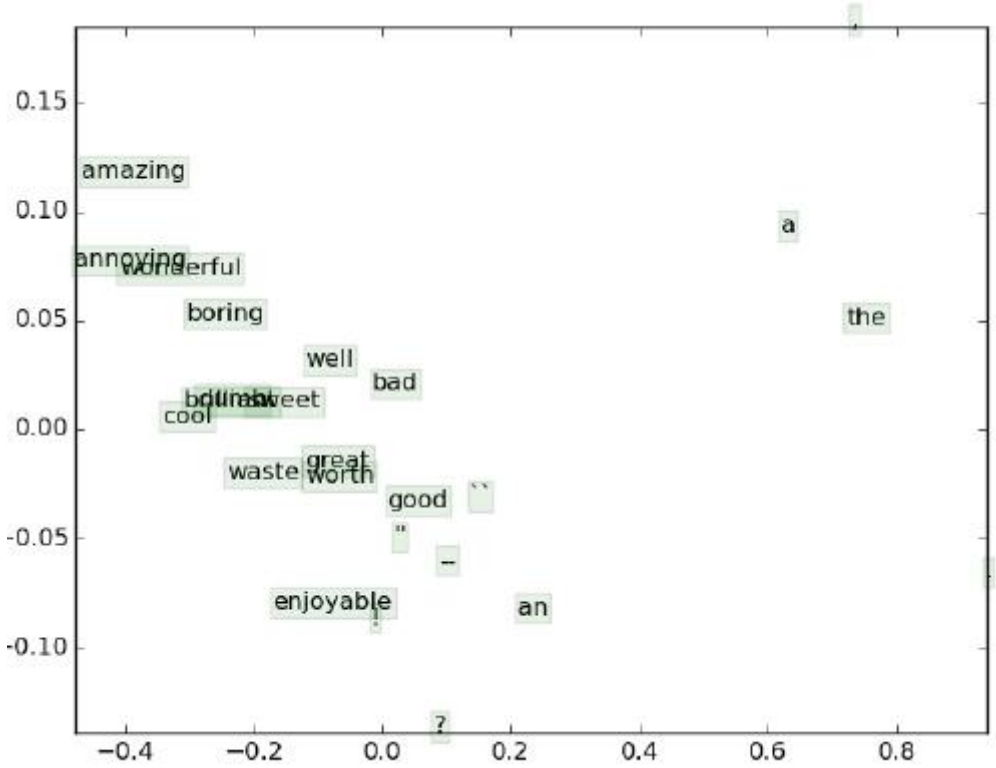

(part h) 附加题（5分）

在代码`q3_word2vec.py`中完成对CBOW的实现。*注释：这部分内容是可选的，但是在d部分中关于CBOW的梯度推导在这里并不适用！*

```
1. def cbow(currentWord, C, contextWords, tokens, inputVectors, outputVectors,
2.     dataset, word2vecCostAndGradient = softmaxCostAndGradient):
3.     """
4.         word2vec的CBOW模型
5.     """
6.     cost = 0
7.     gradIn = np.zeros(inputVectors.shape)
8.     gradOut = np.zeros(outputVectors.shape)
9.      D = inputVectors.shape[1]
10.     predicted = np.zeros((D,))
11.     indices = [tokens[cwd] for cwd in contextWords]
12.     for idx in indices:
13.         predicted += inputVectors[idx, :]
14.     cost, gp, gradOut = word2vecCostAndGradient(predicted,
   tokens[currentWord], outputVectors, dataset)
15.     gradIn = np.zeros(inputVectors.shape)
16.     for idx in indices:
17.         gradIn[idx, :] += gp
18.     return cost, gradIn, gradOut
```

4 情感分析（20分）

现在，随着词向量的训练，我们准备展示一个简单的情感分析案例。随着词向量的训练，我们准备展示一个简单的情感分析。对于每条Stanford Sentiment Treebank数据集中的句子，将句子中全体词向量的平均值算作其特征值，并试图预测所提句子中的情感层次。短语的情感层次使用真实数值在原始数据集中表示，并被我们用以下5个类别来表示：

“超级消极”，“比较消极”，“中立”，“积极”，“非常积极”

对其分别进行从0到4的编码。在这一部分，你将学习用SGD来训练一个softmax回归机，并且通过不断地训练／调试验证来提高回归机的泛化能力。

(part a)（10分）

实现一个句子的特征生成器和softmax回归机。在代码`q4_softmaxreg.py`中完成对这个任务的实现，并运行命令`python q4_ softmaxreg.py`，对刚才完成的功能函数进行调试。

```
1. import numpy as np
2. import random
3. from cs224d.data_utils import *
4. from q1_softmax import softmax
5. from q2_gradcheck import gradcheck_naive
6. from q3_sgd import load_saved_params
7. def getSentenceFeature(tokens, wordVectors, sentence):
8.     """
9.         简单粗暴的处理方式，直接对句子的所有词向量求平均做为情感分析的输入
10.    """
11.    # 输入:
12.    # - tokens: a dictionary that maps words to their indices in the word
   vector list
13.    # - wordVectors: word vectors (each row) for all tokens
14.    # - sentence: a list of words in the sentence of interest
15.    # 输出:
16.    # - sentVector: feature vector for the sentence
17.    sentVector = np.zeros((wordVectors.shape[1],))
18.    indices = [tokens[word] for word in sentence]
19.    sentVector = np.mean(wordVectors[indices, :], axis=0)
20.    return sentVector
21. def softmaxRegression(features, labels, weights, regularization = 0.0,
   nopredictions = False):
22.    """ Softmax Regression """
23.    # 完成加正则化的softmax回归
24.    # 输入:
25.    # - features: feature vectors, each row is a feature vector
26.    # - labels: labels corresponding to the feature vectors
27.    # - weights: weights of the regressor
28.    # - regularization: L2 regularization constant
29.    # 输出:
30.    # - cost: cost of the regressor
31.    # - grad: gradient of the regressor cost with respect to its weights
32.    # - pred: label predictions of the regressor (you might find np.argmax
   helpful)
```

```
    prob = softmax(features.dot(weights))
    if len(features.shape) > 1:
        N = features.shape[0]
    else:
        N = 1
    # A vectorized implementation of    1/N * sum(cross_entropy(x_i, y_i)) +
1/2*|w|^2
    cost = np.sum(-np.log(prob[range(N), labels])) / N
    cost += 0.5 * regularization * np.sum(weights ** 2)
    grad = np.array(prob)
    grad[range(N), labels] -= 1.0
    grad = features.T.dot(grad) / N
    grad += regularization * weights
    if N > 1:
        pred = np.argmax(prob, axis=1)
    else:
        pred = np.argmax(prob)
    if nopredictions:
        return cost, grad
    else:
        return cost, grad, pred
def accuracy(y, yhat):
    """ Precision for classifier """
    assert(y.shape == yhat.shape)
    return np.sum(y == yhat) * 100.0 / y.size
def softmax_wrapper(features, labels, weights, regularization = 0.0):
    cost, grad, _ = softmaxRegression(features, labels, weights,
        regularization)
    return cost, grad
def sanity_check():
    """
    Run python q4_softmaxreg.py.
    """
    random.seed(314159)
    np.random.seed(265)
    dataset = StanfordSentiment()
    tokens = dataset.tokens()
    nWords = len(tokens)
    _, wordVectors0, _ = load_saved_params()
    wordVectors = (wordVectors0[:nWords,:] + wordVectors0[nWords:,:])
    dimVectors = wordVectors.shape[1]
    dummy_weights = 0.1 * np.random.randn(dimVectors, 5)
    dummy_features = np.zeros((10, dimVectors))
    dummy_labels = np.zeros((10,), dtype=np.int32)
    for i in xrange(10):
        words, dummy_labels[i] = dataset.getRandomTrainSentence()
        dummy_features[i, :] = getSentenceFeature(tokens, wordVectors, words)
```

```
    print "==== Gradient check for softmax regression ===="
    gradcheck_naive(lambda weights: softmaxRegression(dummy_features,
        dummy_labels, weights, 1.0, nopredictions = True), dummy_weights)
    print "\n=== Results ==="
    print softmaxRegression(dummy_features, dummy_labels, dummy_weights, 1.0)
if __name__ == "__main__":
    sanity_check()
```

(part b)（2分）

解释当分类语料少于三句时为什么要引入正则化（实际上在大多数机器学习任务都这样）。

解答：为了避免训练集的过拟合以及对未知数据集的适应力不佳现象。

(part c)（4分）

在`q4 sentiment.py`中完成超参数的实现代码从而获取“最佳”的惩罚因子。**你是如何选择的？报告你的训练、调试和测试精度，在最多一个句子中校正你的超参数选定方法。** *注释：在开发中应该获取至少30%的准确率。*

解答：参考值为1e-4，在调试、开发和测试过程中准确率分别为29.1%，31.4%和27.6%

```
import numpy as np
import matplotlib.pyplot as plt
from cs224d.data_utils import *
from q3_sgd import load_saved_params, sgd
from q4_softmaxreg import softmaxRegression, getSentenceFeature, accuracy,
  softmax_wrapper
# 试试不同的正则化系数，选最好的
REGULARIZATION = [0.0, 0.00001, 0.00003, 0.0001, 0.0003, 0.001, 0.003, 0.01]
# 载入数据集
dataset = StanfordSentiment()
tokens = dataset.tokens()
nWords = len(tokens)
# 载入预训练好的词向量
_, wordVectors0, _ = load_saved_params()
wordVectors = (wordVectors0[:nWords,:] + wordVectors0[nWords:,:])
dimVectors = wordVectors.shape[1]
# 载入训练集
trainset = dataset.getTrainSentences()
nTrain = len(trainset)
trainFeatures = np.zeros((nTrain, dimVectors))
trainLabels = np.zeros((nTrain,), dtype=np.int32)
for i in xrange(nTrain):
    words, trainLabels[i] = trainset[i]
    trainFeatures[i, :] = getSentenceFeature(tokens, wordVectors, words)
# 准备好训练集的特征
devset = dataset.getDevSentences()
nDev = len(devset)
devFeatures = np.zeros((nDev, dimVectors))
```

```
devLabels = np.zeros((nDev,), dtype=np.int32)
for i in xrange(nDev):
    words, devLabels[i] = devset[i]
    devFeatures[i, :] = getSentenceFeature(tokens, wordVectors, words)
# 尝试不同的正则化系数
results = []
for regularization in REGULARIZATION:
    random.seed(3141)
    np.random.seed(59265)
    weights = np.random.randn(dimVectors, 5)
    print "Training for reg=%f" % regularization
    # batch optimization
    weights = sgd(lambda weights: softmax_wrapper(trainFeatures, trainLabels,
        weights, regularization), weights, 3.0, 10000, PRINT_EVERY=100)
    # 训练集上测效果
    _, _, pred = softmaxRegression(trainFeatures, trainLabels, weights)
    trainAccuracy = accuracy(trainLabels, pred)
    print "Train accuracy (%%): %f" % trainAccuracy
    # dev集合上看效果
    _, _, pred = softmaxRegression(devFeatures, devLabels, weights)
    devAccuracy = accuracy(devLabels, pred)
    print "Dev accuracy (%%): %f" % devAccuracy
    # 保存结果权重
    results.append({
        "reg" : regularization,
        "weights" : weights,
        "train" : trainAccuracy,
        "dev" : devAccuracy})
# 输出准确率
print ""
print "=== Recap ==="
print "Reg\t\tTrain\t\tDev"
for result in results:
    print "%E\t%f\t%f" % (
        result["reg"],
        result["train"],
        result["dev"])
print ""
# 选最好的正则化系数
BEST_REGULARIZATION = None
BEST_WEIGHTS = None
best_dev = 0
for result in results:
    if result["dev"] > best_dev:
        best_dev = result["dev"]
        BEST_REGULARIZATION = result["reg"]
        BEST_WEIGHTS = result["weights"]
```

```
# Test your findings on the test set
testset = dataset.getTestSentences()
nTest = len(testset)
testFeatures = np.zeros((nTest, dimVectors))
testLabels = np.zeros((nTest,), dtype=np.int32)
for i in xrange(nTest):
    words, testLabels[i] = testset[i]
    testFeatures[i, :] = getSentenceFeature(tokens, wordVectors, words)
_, _, pred = softmaxRegression(testFeatures, testLabels, BEST_WEIGHTS)
print "Best regularization value: %E" % BEST_REGULARIZATION
print "Test accuracy (%%): %f" % accuracy(testLabels, pred)
# 画出正则化和准确率的关系
plt.plot(REGULARIZATION, [x["train"] for x in results])
plt.plot(REGULARIZATION, [x["dev"] for x in results])
plt.xscale('log')
plt.xlabel("regularization")
plt.ylabel("accuracy")
plt.legend(['train', 'dev'], loc='upper left')
plt.savefig("q4_reg_v_acc.png")
plt.show()
```

(d)（4分）绘出在训练和开发过程中的分类准确率，并在x轴使用对数刻度来对正则化值进行相关设置。这应该自动化的进行。**包括在你作业中详细展示的坐标图`q4_reg_acc.png`**。简明解释最多三个句子在此坐标图中的显示情况。

解答:

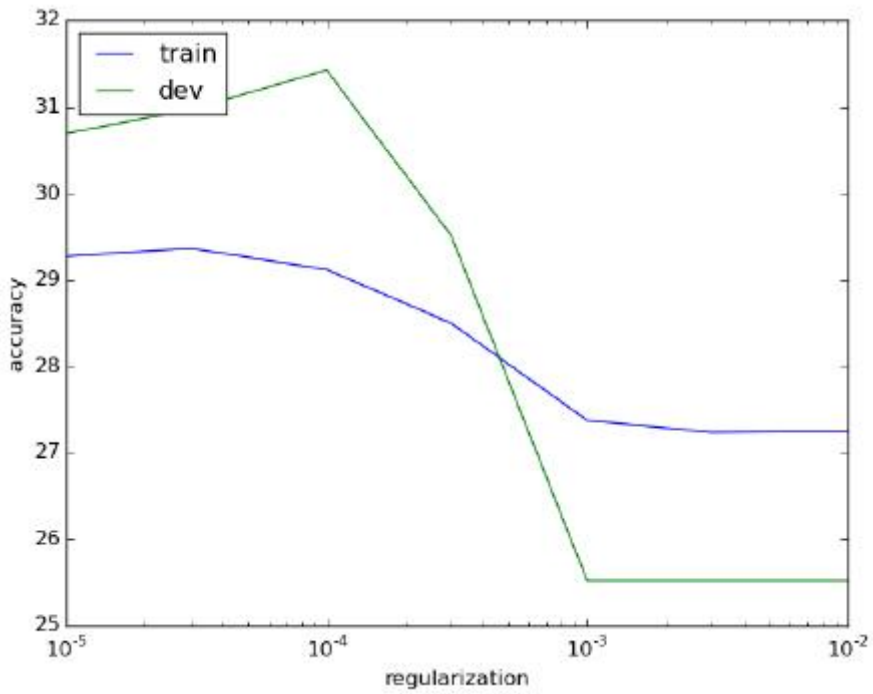

普及数据思维 传播数据文化

We talk data We deliver knowledge

长按二维码 · 关注大数据文摘

数据科学沙龙

扫一扫二维码，加入该群。